

用語の整理

- ・ 一般線形モデル General Linear Model
 - ・ t検定や分散分析も線形モデルだよね
- ・ 一般化線形モデル Generalized Linear Model
 - ・ 様々な分布を使えるモデリング

表 15.1 一般化線形モデルについて：予測変数 x の様々な尺度タイプに対する典型的な線形関数 $\text{lin}(x)$

| 予測変数 x の尺度タイプ | | | | | |
|-----------------|--------------------------------|-----------------------|---|--|--|
| | | 量的 | | 名義的 | |
| 単一の群 | 2つの群 | 単一の予測変数 | 複数の予測変数 | 単一の因子 | 複数の因子 |
| β_0 | $\beta_{x=1}$ $\beta_{x=2}$ | $\beta_0 + \beta_1 x$ | β_0 $+ \sum_k \beta_k x_k$ $+ \sum_{j,k} \beta_{j \times k} x_j x_k$ $+ \left[\begin{array}{c} \text{より高次の} \\ \text{交互作用} \end{array} \right]$ | β_0 $+ \vec{\beta} \cdot \vec{x}$ | β_0 $+ \sum_k \vec{\beta}_k \cdot \vec{x}_k$ $+ \sum_{j,k} \vec{\beta}_{j \times k} \cdot \vec{x}_{j \times k}$ $+ \left[\begin{array}{c} \text{より高次の} \\ \text{交互作用} \end{array} \right]$ |

値 $\text{lin}(x)$ は表 15.2 に示されている関数によって被予測データに対してマッピングされる。

表 15.2 一般化線形モデルについて： 典型的なノイズ分布と被予測変数 y の様々な尺度タイプを記述するための逆リンク関数

| 被予測変数 y 尺度タイプ | 典型的なノイズ分布 $y \sim \text{pdf}(\mu, [\text{parameters}])$ | 典型的逆リンク関数 $\mu = f(\text{lin}(x), [\text{parameters}])$ |
|--------------------|--|---|
| 量的 | $y \sim \text{正規分布}(\mu, \sigma)$ | $\mu = \text{lin}(x)$ |
| 二分值 | $y \sim \text{ベルヌーイ分布}(\mu)$ | $\mu = \text{ロジスティック関数}(\text{lin}(x))$ |
| 名義 | $y \sim \text{カテゴリーカル分布}(\dots, \mu_k, \dots)$ | $\mu_k = \frac{\exp(\text{lin}_k(x))}{\sum_c \exp(\text{lin}_c(x))}$ |
| 順序 | $y \sim \text{カテゴリーカル分布}(\dots, \mu_k, \dots)$ | $\mu_k = \frac{\Phi((\theta_k - \text{lin}(x)) / \sigma)}{\Phi((\theta_k - \text{lin}(x)) / \sigma) - \Phi((\theta_{k-1} - \text{lin}(x)) / \sigma)}$ |
| カウント | $y \sim \text{ポアソン分布}(\mu)$ | $\mu = \exp(\text{lin}(x))$ |

値 μ は予測されたデータの中心傾向 (平均である必要はない)。予測変数は x , $\text{lin}(x)$ は表 15.1 で示されているような x の線形関数。

ベルヌーイ回帰の例

- ・ ロジスティック回帰だが分布の名前を冠するならばベルヌーイ分布なので
- ・ ベルヌーイ分布は試行回数が1の二項分布。コインの裏か表が出る確率, θ だと考えれば良い
- ・ ただし, 成功率 θ は0から1の範囲の数字

ベルヌーイ回帰の例

- ・ ロジスティック関数で変換された μ がベルヌーイ分布に従う, という形でモデリングする
- ・ ロジスティック関数

$$f(x) = \frac{1}{1 + \exp(-x)}$$

- ・ Stanにはinv_logit関数として実装されているのでそれを使ってコードを書く

```
data{
  int<lower=0> L;
  real X[L];
  int<lower=0> Y[L];
}

parameters{
  real beta;
}

transformed parameters{
  real<lower=0> theta[L];
  for(l in 1:L){
    theta[l] = inv_logit(X[l]*beta);
  }
}

model{
  for(l in 1:L){
    Y[l] ~ bernoulli(theta[l]);
  }
}
```

```
data{
  int<lower=0> L;
  real X[L];
  int<lower=0> Y[L];
}

parameters{
  real beta;
}

model{
  for(l in 1:L){
    Y[l] ~ bernoulli_logit(X[l]*beta);
  }
}
```

変換とセットになっている関数も

ポアソン回帰の例

- ・ ポアソン分布
- ・ $Y_i \sim \text{Poisson}(\lambda)$
- ・ 平均パラメータ λ だけの分布
- ・ データが整数であること, パラメータが正の値しかとらないことに注意。

ポアソン回帰の例

- ・ ポアソン分布
- ・ $Y_i \sim \text{Poisson}(\lambda)$
- ・ 平均パラメータ λ だけの分布
- ・ データが整数であること, パラメータが正の値しかとらないことに注意。

```
data{
  int<lower=0> L;
  real X[L];
  int<lower=0> Y[L];
}

parameters{
  real beta;
}

transformed parameters{
  real<lower=0> theta[L];
  for(l in 1:L){
    theta[l] = exp(X[l]*beta);
  }
}

model{
  for(l in 1:L){
    Y[l] ~ poisson(theta[l]);
  }
}
```

```
data{
  int<lower=0> L;
  real X[L];
  int<lower=0> Y[L];
}

parameters{
  real beta;
}

model{
  for(l in 1:L){
    Y[l] ~ poisson_log(X[l]*beta);
  }
}
```

変換とセットになっている関数も

ちょっと追加

階層線形モデルの別解

- ・ 階層線形モデルはベイズの特権ではない
- ・ 従来の最尤法で複雑なモデルになると対応しきれないので、推定法としてベイズを利用するというながれもあった

#BSJ_SS2017

階層線形モデリング

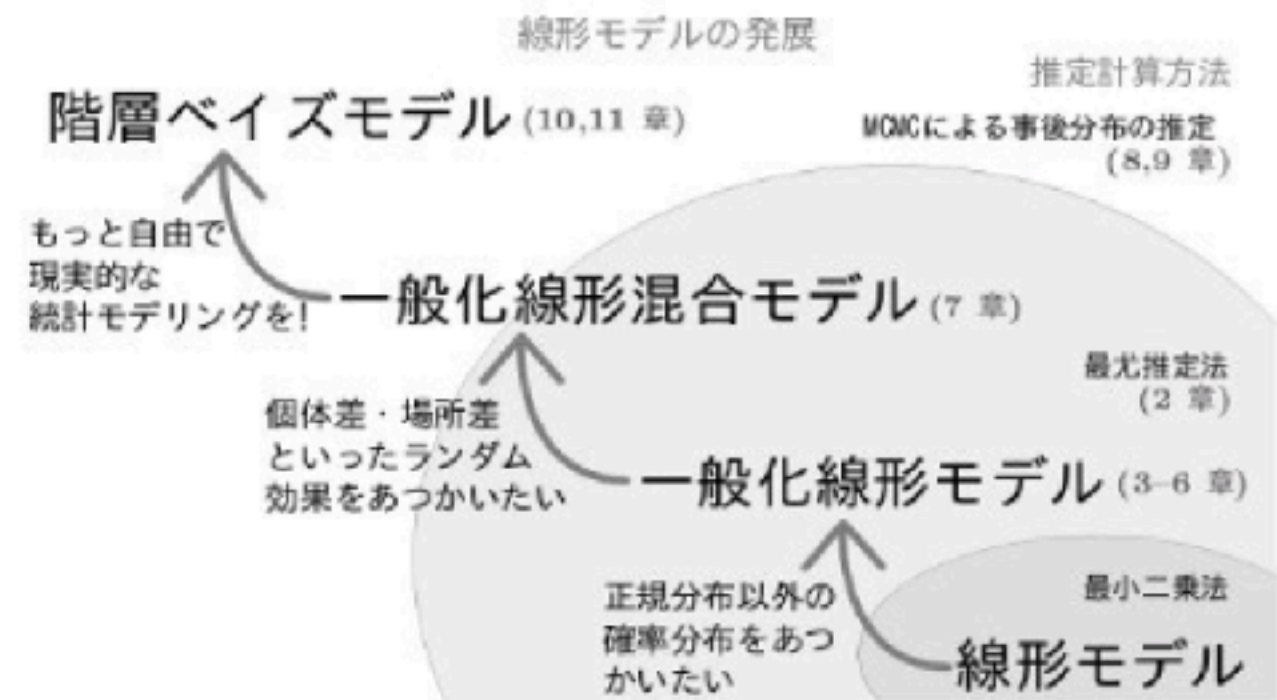


図 1.2 線形モデルを発展させる説明のプラン。まずポアソン分布や二項分布を使った一般化線形モデル (GLM) を導入し、それを現実的なデータ解析に使えるように階層ベイズモデル化する。

久保 (2012) 「データ解析のための統計モデリング入門」より

階層線形モデルの別解

- ・ 最尤法で推定するにはlmerパッケージをどうぞ
- ・ ちゃんと米印も出してくれるlmerTestパッケージからの利用がオススメ

```
library(lmerTest)
result.HLM <- lmer(Y~X+(1|team),data=dat)
summary(result.HLM)
```

階層線形モデルの別解

- ・ 最尤法で推定するにはlmerパッケージをどうぞ
- ・ ちゃんと米印も出してくれるlmerTestパッケージからの利用がオススメ

```
library(lmerTest)
result.HLM <- lmer(Y~X+(1|team),data=dat)
summary(result.HLM)
|
```

切片のみ異なるモデル

#

```
Linear mixed model fit by REML t-tests use Satterthwaite ap
degrees of freedom [lmerMod]
Formula: Y ~ X + (1 | team)
Data: dat
```

```
REML criterion at convergence: 960
```

```
Scaled residuals:
```

| Min | 1Q | Median | 3Q | Max |
|----------|----------|---------|---------|---------|
| -2.06753 | -0.79008 | 0.04376 | 0.58145 | 2.41985 |

```
Random effects:
```

| Groups | Name | Variance | Std.Dev. |
|----------|-------------|----------|----------|
| team | (Intercept) | 34497.7 | 185.74 |
| Residual | | 119.1 | 10.91 |

```
Number of obs: 120, groups: team, 6
```

```
Fixed effects:
```

| | Estimate | Std. Error | df | t value | Pr(> t) |
|-------------|-----------|------------|-----------|---------|-------------|
| (Intercept) | 753.94309 | 75.85388 | 5.09000 | 9.939 | 0.00016 *** |
| X | 4.97348 | 0.01625 | 113.08000 | 306.117 | < 2e-16 *** |

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Correlation of Fixed Effects:
```

```
(Intr)
X -0.024
```

切片のみ異なるモデル

モデル式の記述

- ・ モデル式の記述は次のようにする
- ・ 固定効果の独立変数と従属変数をチルダでつなぐ
- ・ 変量効果はカッコに入れて指定する

```
library(lmerTest)
result.HLM <- lmer(Y~X+(1|team), data=dat)
summary(result.HLM)
```

```
result.HLM2 <- lmer(Y~X+(1+X|team), data=dat)
summary(result.HLM2)
```

Bonus Truck

| | | | | | | | | | |
|---|-------------|------------|----------|---------|------------------------------|---------|---------|------|--|
| > summary(result.HLM2) | | | | | > fit8d | | | | |
| Linear mixed model fit by REML t-tests use Satt Inference | | | | | 4 chains, each with iter=500 | | | | |
| degrees of freedom [lmerMod] | | | | | post-warmup draws per chain: | | | | |
| Formula: Y ~ X + (1 + X team) | | | | | | | | | |
| Data: dat | | | | | | | | | |
| REML criterion at convergence: 989 | | | | | | | | | |
| Scaled residuals: | | | | | | | | | |
| Min | 1Q | Median | 3Q | Max | base0 | mean | se_mean | | |
| -2.17824 | -0.59814 | -0.01952 | 0.66576 | 2.13352 | baseSig | 975.47 | 1.09 | 67.5 | |
| | | | | | base[1] | 156.51 | 0.96 | 58.4 | |
| | | | | | base[2] | 809.68 | 0.06 | 4.3 | |
| | | | | | base[3] | 859.15 | 0.06 | 4.3 | |
| | | | | | base[4] | 1112.67 | 0.06 | 4.3 | |
| | | | | | base[5] | 865.13 | 0.08 | 5.0 | |
| | | | | | base[6] | 1041.70 | 0.08 | 5.0 | |
| | | | | | base[6] | 1156.11 | 0.11 | 7.3 | |
| | | | | | beta0 | 10.62 | 0.06 | 3.3 | |
| | | | | | betaSig | 8.61 | 0.05 | 3.0 | |
| | | | | | beta[1] | 8.10 | 0.00 | 0.0 | |
| | | | | | beta[2] | 3.34 | 0.00 | 0.0 | |
| | | | | | beta[3] | 24.64 | 0.00 | 0.0 | |
| | | | | | beta[4] | 3.94 | 0.00 | 0.0 | |
| | | | | | beta[5] | 13.76 | 0.00 | 0.0 | |
| | | | | | beta[6] | 9.63 | 0.00 | 0.0 | |
| | | | | | sig | 10.20 | 0.01 | 0.0 | |
| | | | | | lp__ | -385.78 | 0.06 | 3.3 | |
| Random effects: | | | | | | | | | |
| Groups | Name | Variance | Std.Dev. | Corr | | | | | |
| team | (Intercept) | 21811.75 | 147.688 | | | | | | |
| | X | 62.21 | 7.888 | 0.68 | | | | | |
| | Residual | 101.42 | 10.071 | | | | | | |
| Number of obs: 120, groups: team, 6 | | | | | | | | | |
| Fixed effects: | | | | | | | | | |
| | Estimate | Std. Error | df | t value | | | | | |
| (Intercept) | 974.022 | 60.329 | 5.600 | 16.145 | | | | | |
| X | 10.568 | 3.220 | 5.116 | 3.282 | | | | | |

モデル式の記述

- Stanのチームが作ったrstanarmパッケージを使うと、lmerの書き方と同じモデルで変量効果モデルをベイズ推定できる

rstanarm-package {rstanarm}

R Documentation

Applied Regression Modeling via RStan

Description



Stan Development Team

An appendage to the **rstan** package that enables some of the most common applied regression models to be estimated using Markov Chain Monte Carlo, variational approximations to the posterior distribution, or optimization. The **rstanarm** package allows these models to be specified using the customary R modeling